

VLA Study Note

Summary

- VLA 모델(Vision-Language-Action Model)은 텍스트, 비디오, 시연(Demonstration) 등의 인풋을 받아 액션을 생성하는 로봇 파운데이션 모델들을 일컫는다. 즉, 인공지능 로봇에 들어가는 일종의 생성형 인공지능이다.

VLA?

- 보고(Vision), 읽고(Language), 행동(Action)하는 법을 한 번에 배우는 로봇 AI 기술임
- Vision(시각) : 로봇의 카메라를 통해 들어오는 실시간 주변 환경 데이터를 인식함.
- Language(언어) : 인간이 내리는 자연어 명령을 해석함 (ex. 빨간 컵 집어 쟁반 위에 놔)
- Action(행동) : 인식한 환경과 명령을 바탕으로 로봇 팔의 관절 각도나 이동 경로 같은 물리적 제어 신호를 생성함.

VLA 등장 배경

- 기존 로봇 제어의 한계
- 과거의 로봇 공학은 특정 환경에서 특정 작업만 수행하도록 사람이 일일이 코딩을 했음. 이에 수만 줄의 코드가 필요했고 상황이 조금만 바뀌어도 로봇이 제대로 작동하지 않음
- 수학적 계산이나 바둑 같은 고등 추론은 AI에게 쉽지만, 컵을 집는 것 같은 기본적인 신체 능력은 매우 어렵다는 '모라벨의 역설'에 부딪힘
- 파운데이션 모델의 성공
- 2020년대에 들어 GPT와 같은 거대 모델들이 범용성을 증명하면서 로봇 분야에도 하나의 거대 모델이 모든 로봇 동작을 배울 수 있지 않을까?라는 아이디어가 등장함
- 배고프다 → 먹을 것이 필요하다 → 냉장고에 간다.까지의 인과관계를 잘 이해하게 됨
- 텍스트뿐만 아니라 이미지를 이해하는 VLM(Vision-Language Model)이 발전하면서, 로봇이 눈으로 보는 세상을 언어적 상식과 연결할 수 있게 됨
- Embodied AI(체화된 인지)에 대한 갈증

- AI 연구자들이 진정한 지능은 소프트웨어 속에만 존재하는 것이 아니라, 물리적 신체를 가지고 세상과 상호작용할 때 완성된다고 믿기 시작함.

VLA 작동원리

1) 토큰화(Tokenization) : 이미지 데이터와 텍스트 명령을 AI가 이해할 수 있는 토큰 형태로 변환한다.

2) 임베딩 통합 : 시각 정보와 언어 정보를 하나의 공간에서 융합한다.

3) 행동 출력 : 모델의 출력층에서 텍스트 대신 로봇의 행동 토큰을 내뱉는다. 예를 들어, 출력값이 "Move_Arm(x,y,z)"와 같은 제어 신호로 매핑되는 방식이다.

- VLA 모델의 함수 관계는 대략 다음과 같이 표현할 수 있다.

$$A_t = f(V_0, L, S_0)$$

A_t : t시점의 행동(Action)

V_0 : 현재까지의 시각적 입력(Vision)

L : 자연어 명령(Language)

S_0 : 로봇의 현재 상태(State, 관절 위치 등)

VLA의 주요 특징 (왜 사용되는가?)

- 일반화(Generalization) : 학습하지 않은 새로운 물체나 환경에서도 명령을 수행할 수 있음.
- 상식 추론(Reasoning) : "배가 고파"라고 말하면 로봇이 스스로 음식을 찾아 가져오는 수준의 추론이 가능해짐.
- 제로샷 학습(Zero-Shot) : 한 번도 해보지 않은 동작을 추가 프로그래밍 없이 수행할 수 있음.
- 유연성 : 특정 로봇뿐만 아니라 다양한 형태의 하드웨어(드론, 4족 보행 로봇, 협동 로봇 등)에 이식하기 유리함.

<https://youtu.be/8llrd7yM7H0?si=6He4uqCtrM4x0e42>

https://youtube.com/shorts/Q0ytT4yqn3A?si=61_ZldrWI02E1AVJ

실제 VLA가 사용되고 있는 사례들이다.

현재 한계와 연구 과제

- 데이터 부족(The Data Gap) : 인터넷에는 텍스트와 영상 데이터는 넘쳐나지만, 로봇이 실제로 움직인 행동 데이터가 매우 부족하다.
- 실시간성(Latency) : 모델이 너무 거대하면 로봇이 명령을 이해하고 움직이는 데 시간이 걸린다. 현장에서는 1초의 지연도 사고로 이어질 수 있어 경량화가 필수적이다.
- 안전 및 윤리 : AI가 스스로 판단해 움직이기 때문에, 예상치 못한 동작으로 인간에게 해를 끼칠 경우에 대한 안전장치 연구가 활발하다.

한계를 해결하기 위한 방법?

- 데이터부족
 1. Sim-to-Real: 고정밀 물리 시뮬레이터에서 가상 학습을 먼저 시킨 후 현실로 전이
 2. 유튜브 등 비디오 활용: 로봇 제어 데이터가 없어도 사람이 행동하는 영상을 통해 '물리적 상식'을 사전 학습
 3. 교차 로봇 데이터: 형태가 다른 다양한 로봇들의 데이터를 통합해 하나의 거대 VLA가 학습하도록 공유.
- 실시간성 부족 해결(속도 최적화)
 1. 계층적 제어: VLA는 0.5초마다 큰 방향만 짜고, 실제 관절 움직임은 가볍고 빠른 하위 제어기가 0.01초마다 실행
 2. 행동 청킹: 한 번 추론할 때 미래의 행동 시퀀스를 묶어서 한 번에 출력하여 연산 부담을 축소.
 3. 모델 경량화: 지식 증류 및 양자화를 통해 로봇에 탑재되는 온디바이스 모델 크기를 줄이고 속도 향상
- 안전 및 윤리 한계 해결(위험제어)

1. 수학적 가드레일: VLA의 명령을 로봇에 바로 주지 않고, 제어 이론 기반 필터를 거쳐 물리적 충돌이나 위험 명령을 실시간 차단
2. 행동 정렬: 사람을 공격하거나 유해한 명령을 내릴 경우 로봇이 스스로 거부하도록 윤리 및 안전 규정을 강화 학습
3. 센서 크로스 체크: 시각적 환각을 방지하기 위해 3D 센서나 촉각 센서 데이터와 교차 검증하여 안정성 확보

실전 응용 분야

- 스마트 팩토리 : 공정 라인이 바뀔 때마다 코딩을 새로 하는 대신, 로봇에게 말로 지시하여 새로운 작업을 즉시 수행하게 한다.
- 물류 자동화 : 비정형화된 택배 상자나 물건들을 로봇이 알아서 분류하고 적재한다.
- 가정용 서비스 로봇 : "거실 청소해줘", "냉장고에서 물 좀 가져다줘"같은 일상적인 명령을 수행한다.